

Лекция 10

Анализ данных в python

- Основы Jupyter
- Numpy
- Pandas
- Визуализация

Jupyter Notebook Basics

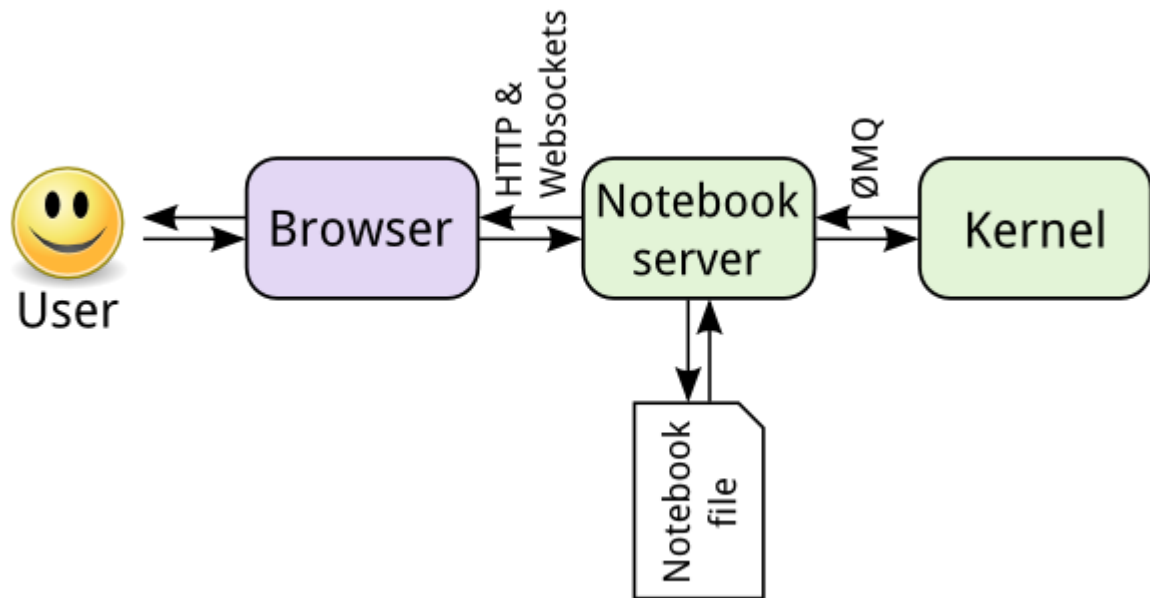
- Что такое Jupyter Notebook и как с ним работать
- Виды ячеек: код, markdown, формулы
- Магические команды
- Shell-команды
- Jupyter в IDE

```
pip install jupyter
jupyter notebook
```

Архитектура

REPL - Read-Evaluate-Print Loop

```
ec2-user@ip-10-0-1... ㉿1  will@ip-10-0-21-248... ㉿2
[will:~/my_project] $ python
Python 2.7.13 (default, Mar 26 2017, 08:03:07)
[GCC 4.2.1 Compatible Apple LLVM 8.0.0 (clang-800.0.42.1)] on darwin
Type "help", "copyright", "credits" or "license" for more information.
>>> 2 + 2
4
>>> print "Hello world"
Hello world
>>> print("Hello world")
Hello world
>>>
[will:~/my_project] $ python3
Python 3.6.1 (default, Apr  5 2017, 17:12:54)
[GCC 4.2.1 Compatible Apple LLVM 8.1.0 (clang-802.0.38)] on darwin
Type "help", "copyright", "credits" or "license" for more information.
>>> print "Hello world"
File "<stdin>", line 1
    print "Hello world"
      ^
SyntaxError: Missing parentheses in call to 'print'
>>> print("Hello world")
Hello world
>>> import datetime
```



https://jupyter.readthedocs.io/en/latest/architecture/how_jupyter_ipython_work.html
(https://jupyter.readthedocs.io/en/latest/architecture/how_jupyter_ipython_work.html)

Jupyter + Cloud



Интерактивная среда разработки

```
In [165]: a = 10  
          b = 3  
          a + b
```

```
Out[165]: 13
```

```
In [166]: def is_odd(num):  
          return bool(num % 2)  
  
          is_odd(17)
```

Out[166]: True

```
In [169]: from math import pi  
          pi
```

Out[169]: 3.1415926536

Shortcuts

Esc - enables Command Mode

Enter - enables Edit Mode

h - in Command Mode shows keyboard shortcuts help

```
In [ ]: a = 10  
        b = 3  
        a + b
```

Markdown

Header Level 1

...

Header Level 4

This is bold text

And this is Italic

Here's an example of Monospace font

1. Item 1
2. Item 2
 - sub item 1
 - sub item 2
3. Item 3

HTML



LaTeX

$$f'(a) = \lim_{x \rightarrow a} \frac{f(x) - f(a)}{x - a}$$

Магические команды

Справка по командам

In [170]: `%lsmagic`

Out[170]: Available line magics:

```
%alias %alias_magic %autoawait %autocall %automagic %autosave %bookmark
%cd %clear %cls %colors %conda %config %connect_info %copy %ddir %de
bug %dhist %dirs %doctest_mode %echo %ed %edit %env %gui %hist %his
tory %killbgscripts %ldir %less %load %load_ext %loadpy %logoff %logo
n %logstart %logstate %logstop %ls %lsmagic %macro %magic %matplotlib
%mkdir %more %notebook %page %pastebin %pdb %pdef %pdoc %pfile %pinf
o %pinfo2 %pip %popd %pprint %precision %prun %psearch %psource %pus
hd %pwd %pycat %pylab %qtconsole %quickref %recall %rehashx %reload_e
xt %ren %rep %rerun %reset %reset_selective %rmdir %run %save %sc %
set_env %store %sx %system %tb %time %timeit %unalias %unload_ext %w
ho %who_ls %whos %xdel %xmode
```

Available cell magics:

```
%%! %%HTML %%SVG %%bash %%capture %%cmd %%debug %%file %%html %%java
script %%js %%latex %%markdown %%perl %%prun %%pypy %%python %%python
2 %%python3 %%ruby %%script %%sh %%svg %%sx %%system %%time %%timeit
%%writefile
```

Automagic is ON, % prefix IS NOT needed for line magics.

In [171]: `%quickref`

```
In [172]: %alias_magic?
```

```
In [174]: range?
```

% vs %%

```
In [175]: # single line commands
%time [x**2 for x in range(1000)][:7];
```

Wall time: 500 µs

```
Out[175]: [0, 1, 4, 9, 16, 25, 36]
```

```
In [176]: %%time
# cell magic command (no blank line or comment at first line)
import time
for _ in range(100):
    time.sleep(0.01)
```

Wall time: 1.02 s

Работа с кодом

```
In [181]: %who
```

```
A      B      a      a_observations  a_slice      b      calc_factori
al      columns      df
effective_series      effectiveness  envs      full_df      group  hosp
itals      idx1      idx2      is_odd
mask      np      patients      pd      pi      sbn      sns      time      valu
e
x      y
```

```
In [182]: %%writefile factorial.py
def calc_factorial(n):
    if n == 1:
        return n
    else:
        return n * calc_factorial(n-1)
```

Overwriting factorial.py

```
In [ ]: %ls .
```

```
In [184]: %pycat factorial.py
```

```
In [186]: # %load factorial.py
def calc_factorial(n):
    if n == 1:
        return n
    else:
        return n * calc_factorial(n-1)
```

```
In [187]: %who function

calc_factorial    is_odd
```

```
In [188]: calc_factorial(5)
```

```
Out[188]: 120
```

shell-команды

```
In [189]: !ls .

0 Jupyter Basics
09 Exceptions & Context Managers
10 Numpy & Pandas
10_numpy_pandas.ipynb
11 Testing
12 Speedup
factorial.py
```

Задание 1

Выведите значение константы `pi`, которую выше импортировали из модуля `math` с двумя знаками после запятой

```
In [ ]:
```

Задание 2

Каково значение переменной окружения `PATH` на вашей системе?

```
In [ ]:
```

Задание 3

Какая версия python установлена в вашем окружении?

In []:

Jupyter + IDE

```
1  #%% mcd
2
3  ## Write a formula
4
5  $$c = \sqrt{a^2 + b^2}$$
6
7  #%% mcd
8
9  ## Draw a scatter chart
10
11 #%%
12
13 import ...
14
15
16 N = 20
17 x = np.random.rand(N)  N: 20
18 print('X-axis values:\n', x)  x: {ndarray: (20,)}
19 y = np.random.rand(N)  N: 20
20 print('Y-axis values:\n', y)  y: {ndarray: (20,)}
21
22 #%% code
```

Write a formula

$$c = \sqrt{a^2 + b^2}$$

Draw a scatter chart

```
4 import numpy as np
import matplotlib.pyplot as plt

N = 20
x = np.random.rand(N)
print('X-axis values:\n', x)
y = np.random.rand(N)
print('Y-axis values:\n', y)
```

X-axis values:

Jupyter: Server: JupyterNotebookSample Variables: example.ipynb x Introspection x

N = {int} 20

area = {ndarray: (20,)} [48.72203933 2062.14825598 997.90253015 152.85218476 2494.5300119, 423.17321033 687.26957251 891.9792298 170.17449852 813.05551135, 65....View as Array

colors = {ndarray: (20,)} [0.88845995 0.58571858 0.35230751 0.58741305 0.91950867 0.27928445, 0.387944 0.50382959 0.76960492 0.92649967 0.38182864 0.8352972, 0.5115....View as Array

x = {ndarray: (20,)} [0.33261835 0.63119016 0.50542995 0.27863948 0.56295504 0.58793002, 0.67978893 0.40284084 0.48756351 0.37355871 0.33196933 0.78113828, 0.582268....View as Array

y = {ndarray: (20,)} [0.98007343 0.21980076 0.85083091 0.95719335 0.94687134 0.03050174, 0.66119853 0.40145986 0.58455203 0.18170648 0.03498327 0.60856864, 0.4533006....View as Array

Special Variables

NumPy

Библиотека для научных вычислений

- Эффективные многомерные массивы
- Высокоуровневые математические функции
- Возможность интегрировать код на C/C++, Fortran

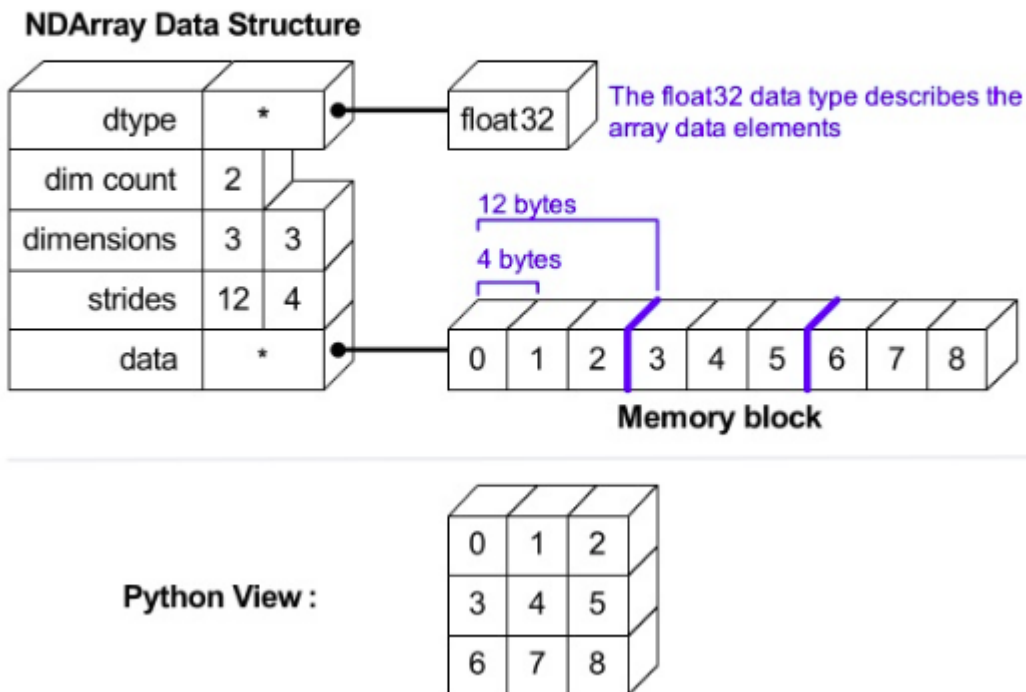
```
In [190]: import numpy as np
          np.__version__
```

```
Out[190]: '1.18.1'
```

numpy.ndarray

Многомерный массив элементов **одного типа** (чаще всего числового), занимающий непрерывный участок памяти

Array Data Structure



```
In [191]: a = np.array([1, 2, 3, 4, 5, 6, 7, 8])
```

```
In [192]: a.dtype
```

```
Out[192]: dtype('int32')
```

```
In [193]: a.astype(np.float32)
```

```
Out[193]: array([1., 2., 3., 4., 5., 6., 7., 8.], dtype=float32)
```

```
In [194]: a.shape
```

```
Out[194]: (8,)
```

```
In [195]: a.reshape((2, 4))
```

```
Out[195]: array([[1, 2, 3, 4],
                 [5, 6, 7, 8]])
```

```
In [198]: a.shape = 4, 2
a
```

```
Out[198]: array([[1, 2],
                 [3, 4],
                 [5, 6],
                 [7, 8]])
```

```
In [199]: a.size
```

```
Out[199]: 8
```

```
In [200]: a.ndim
```

```
Out[200]: 2
```

Специальные виды массивов

```
In [201]: np.zeros((3, 3))
```

```
Out[201]: array([[0., 0., 0.],
                 [0., 0., 0.],
                 [0., 0., 0.]])
```

```
In [202]: np.empty(5)
```

```
Out[202]: array([7.2911220196e-304, 8.2890460585e-317, 4.9406564584e-324,
                 0.0000000000e+000, 2.1219957910e-314])
```

```
In [203]: np.ones((2, 5), dtype=np.int8)
```

```
Out[203]: array([[1, 1, 1, 1, 1],
                 [1, 1, 1, 1, 1]], dtype=int8)
```

```
In [204]: np.random.rand(3, 3)
```

```
Out[204]: array([[0.2148639211, 0.3993791727, 0.2778990899],
                 [0.5832160177, 0.9839696927, 0.3610251097],
                 [0.7258782609, 0.5974873135, 0.0254303019]])
```

Доступ к элементам

Схоже со списками в python: индексы, слайсы, обход в цикле

```
In [205]: A = np.array([[1, 2, 3], [4, 5, 6], [7, 8, 9]])
A
```

```
Out[205]: array([[1, 2, 3],
                 [4, 5, 6],
                 [7, 8, 9]])
```

```
In [206]: A[0]
```

```
Out[206]: array([1, 2, 3])
```

```
In [207]: A[1, 1]
```

```
Out[207]: 5
```

```
In [208]: A[0:2]
```

```
Out[208]: array([[1, 2, 3],  
                [4, 5, 6]])
```

```
In [209]: A[0:2, 0:2]
```

```
Out[209]: array([[1, 2],  
                [4, 5]])
```

```
In [210]: A[:, 2]
```

```
Out[210]: array([3, 6, 9])
```

Значения массива можно изменять используя оба способа - и индексы, и слайсы

```
In [211]: A[0, 0] = 100
```

```
In [212]: A[:, 2] = [0, 0, 0]
```

```
In [213]: A
```

```
Out[213]: array([[100,  2,  0],  
                [  4,  5,  0],  
                [  7,  8,  0]])
```

Memory view

Слайс numpy не создает копию данных (в отличие от списков python), а возвращает так называемый view. Это значит, что если поменять значение в слайсе, то значение в оригинальном массиве также изменится

```
In [214]: a_slice = A[0:2, 0:2]  
a_slice[0, 0] = -22  
A
```

```
Out[214]: array([[ -22,  2,  0],  
                [  4,  5,  0],  
                [  7,  8,  0]])
```

Fancy indexing

Обращение к элементам массива используя другой массив (целочисленный или булевый)

```
In [215]: A = np.array([[1, 2, 3, 4], [5, 6, 7, 8], [9, 10, 11, 12], [13, 14, 15, 16]])  
A
```

```
Out[215]: array([[ 1,  2,  3,  4],  
                [ 5,  6,  7,  8],  
                [ 9, 10, 11, 12],  
                [13, 14, 15, 16]])
```

```
In [216]: idx1 = np.array([0, 1, 2, 3])  
idx2 = np.array([0, 1, 2, 3])
```

```
In [217]: A[idx1, idx2]
```

```
Out[217]: array([ 1,  6, 11, 16])
```

```
In [218]: A
```

```
Out[218]: array([[ 1,  2,  3,  4],  
                [ 5,  6,  7,  8],  
                [ 9, 10, 11, 12],  
                [13, 14, 15, 16]])
```

```
In [220]: idx1 = [  
            [0, 1],  
            [3, 2]  
        ]  
  
idx2 = [  
            [0, 2],  
            [1, 1]  
        ]
```

```
In [224]: A[idx1, idx2]
```

```
Out[224]: array([[ 1,  7],  
                [14, 10]])
```

```
In [225]: B = np.array([1, 2, 3, 4, 5, 6])  
mask = np.array([True, False, False, False, True, False])  
B[mask]
```

```
Out[225]: array([1, 5])
```

```
In [226]: A > 2
```

```
Out[226]: array([[False, False,  True,  True],
                 [ True,  True,  True,  True],
                 [ True,  True,  True,  True],
                 [ True,  True,  True,  True]])
```

```
In [227]: A[A > 5]
```

```
Out[227]: array([ 6,  7,  8,  9, 10, 11, 12, 13, 14, 15, 16])
```

Базовые операции

Арифметические операции

выполняются поэлементно

```
In [228]: a = np.array([20, 30, 40, 50])
          b = np.arange(4)
          a, b
```

```
Out[228]: (array([20, 30, 40, 50]), array([0, 1, 2, 3]))
```

```
In [229]: a - b
```

```
Out[229]: array([20, 29, 38, 47])
```

```
In [230]: a ** b
```

```
Out[230]: array([    1,    30,  1600, 125000], dtype=int32)
```

```
In [231]: 10 * a
```

```
Out[231]: array([200, 300, 400, 500])
```

```
In [232]: a > 35
```

```
Out[232]: array([False, False,  True,  True])
```

Произведение матриц

операция @ или метод dot()

```
In [233]: A = np.array( [[1,1],
                        [0,1]] )
          B = np.array( [[2,0],
                        [3,4]] )
```

```
In [234]: # Поэлементное умножение матриц
A * B
```

```
Out[234]: array([[2, 0],
                [0, 4]])
```

```
In [235]: # Произведение матриц
A @ B
```

```
Out[235]: array([[5, 4],
                [3, 4]])
```

```
In [236]: # ... или
A.dot(B)
```

```
Out[236]: array([[5, 4],
                [3, 4]])
```

Унарные операции

реализованы как методы класса ndarray

```
In [237]: a = np.random.random((2,3))
a
```

```
Out[237]: array([[0.6317556974, 0.6890465697, 0.2038007117],
                [0.1330713379, 0.0508935241, 0.4152276312]])
```

```
In [238]: a.sum()
```

```
Out[238]: 2.1237954719620546
```

```
In [239]: a.min()
```

```
Out[239]: 0.050893524110887656
```

```
In [240]: a.max()
```

```
Out[240]: 0.6890465697247758
```

По умолчанию эти функции просматривают элементы массива как одномерный список.
С помощью аргумента `axis` можно указать, вдоль какой оси выполняются вычисления.

```
In [241]: b = np.arange(12).reshape(3,4)
b
```

```
Out[241]: array([[ 0,  1,  2,  3],
                [ 4,  5,  6,  7],
                [ 8,  9, 10, 11]])
```

```
In [242]: # сумма элементов в каждом столбце  
b.sum(axis=0)
```

```
Out[242]: array([12, 15, 18, 21])
```

```
In [243]: # сумма в каждой строке  
b.sum(axis=1)
```

```
Out[243]: array([ 6, 22, 38])
```

Общие математические функции

```
In [244]: a = np.arange(3)  
a
```

```
Out[244]: array([0, 1, 2])
```

```
In [245]: np.exp(a)
```

```
Out[245]: array([1.          , 2.7182818285, 7.3890560989])
```

```
In [246]: np.sqrt(a)
```

```
Out[246]: array([0.          , 1.          , 1.4142135624])
```

Broadcasting

Правила преобразования размерности массивов, чтобы выполнение поэлементных операций было возможно.

<https://numpy.org/devdocs/user/basics.broadcasting.html>

(<https://numpy.org/devdocs/user/basics.broadcasting.html>)

```
In [247]: x = np.ones((4, 3))  
x.shape
```

```
Out[247]: (4, 3)
```

```
In [248]: y = np.random.rand(3)  
y.shape
```

```
Out[248]: (3,)
```

```
In [249]: (x * y).shape
```

```
Out[249]: (4, 3)
```

Pandas

Библиотека для преобразования и анализа данных в форме таблиц и временных рядов

- множество форматов для импорта/экспорта данных: csv, xml, sql базы данных
- очистка, группировки, объединение дата-сетов
- производительность

```
In [250]: import pandas as pd
          pd.__version__
```

```
Out[250]: '0.25.3'
```

pd.Series

Проиндексированный одномерный массив - сопоставляет каждому значению массива уникальный ключ

Представим, мы работаем с некоторыми данными о результатах тестирования лекарства для нормализации давления.

В качестве индекса будем использовать "имена" пациентов.

В массиве хранится информация о том, эффективно ли лекарство для конкретного пациента.

```
In [251]: patients = ["a", "b", "c", "d", "e", "f"]
          effectiveness = [True, True, True, True, False, False]

          effective_series = pd.Series(effectiveness, index=patients)
          effective_series
```

```
Out[251]: a      True
          b      True
          c      True
          d      True
          e     False
          f     False
          dtype: bool
```

Если нужно больше информации, одного массива уже недостаточно. Такие данные удобно хранить в табличной форме.

pd.DataFrame

Проиндексированная таблица. Можно рассматривать DataFrame как словарь элементов Series

В роли индекса - снова имена пациентов.

В каждой колонке хранится значение отдельного признака для всех пациентов.

Каждая строка - набор всех признаков для конкретного пациента.

```
In [252]: columns = {
    'gender': ['F', 'M', 'M', 'M', 'F', 'M'],
    'sys_initial': [120, 126, 130, 115, 150, 117],
    'dia_initial': [75, 85, 90, 87, 90, 74],
    'sys_final': [115, 123, 130, 118, 130, 121],
    'dia_final': [70, 82, 92, 87, 85, 74],
    'drug_admst': effectiveness
}

df = pd.DataFrame(columns, index=patients)
```

```
In [253]: df
```

```
Out[253]:
```

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
a	F	120	75	115	70	True
b	M	126	85	123	82	True
c	M	130	90	130	92	True
d	M	115	87	118	87	True
e	F	150	90	130	85	False
f	M	117	74	121	74	False

```
In [254]: type(df['sys_initial'])
```

```
Out[254]: pandas.core.series.Series
```

```
In [255]: type(df.loc['a'])
```

```
Out[255]: pandas.core.series.Series
```

Базовый анализ

```
In [256]: df.shape
```

```
Out[256]: (6, 6)
```

In [257]: df.head(2)

Out[257]:

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
a	F	120	75	115	70	True
b	M	126	85	123	82	True

In [258]: df.tail(2)

Out[258]:

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
e	F	150	90	130	85	False
f	M	117	74	121	74	False

In [259]: df.info()

```
<class 'pandas.core.frame.DataFrame'>  
Index: 6 entries, a to f  
Data columns (total 6 columns):  
gender           6 non-null object  
sys_initial      6 non-null int64  
dia_initial      6 non-null int64  
sys_final        6 non-null int64  
dia_final        6 non-null int64  
drug_admst       6 non-null bool  
dtypes: bool(1), int64(4), object(1)  
memory usage: 454.0+ bytes
```

In [260]: df.dia_initial.value_counts()

Out[260]:

90	2
87	1
85	1
74	1
75	1

Name: dia_initial, dtype: int64

In [261]: df.dia_initial.sort_values()

Out[261]:

f	74
a	75
b	85
d	87
c	90
e	90

Name: dia_initial, dtype: int64

Индексация

```
In [262]: df.loc['b']
```

```
Out[262]: gender          M
sys_initial    126
dia_initial     85
sys_final      123
dia_final       82
drug_admst     True
Name: b, dtype: object
```

```
In [263]: df.iloc[1]
```

```
Out[263]: gender          M
sys_initial    126
dia_initial     85
sys_final      123
dia_final       82
drug_admst     True
Name: b, dtype: object
```

```
In [264]: df.dia_initial
```

```
Out[264]: a    75
b    85
c    90
d    87
e    90
f    74
Name: dia_initial, dtype: int64
```

```
In [265]: df.loc['c', 'sys_final']
```

```
Out[265]: 130
```

```
In [266]: df.iloc[2, 2]
```

```
Out[266]: 90
```

```
In [267]: df.loc[:, ['sys_final', 'dia_final']]
```

```
Out[267]:
```

	sys_final	dia_final
a	115	70
b	123	82
c	130	92
d	118	87
e	130	85
f	121	74

```
In [268]: df[(df.sys_initial <= 120) & (df.sys_final > 115)]
```

```
Out[268]:
```

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
d	M	115	87	118	87	True
f	M	117	74	121	74	False

groupBy

Возвращает итератор, каждый элемент которого - фрейм с соответствующим значением

```
In [269]: type(df.groupby('drug_admst'))
```

```
Out[269]: pandas.core.groupby.generic.DataFrameGroupBy
```

```
In [270]: for value, group in df.groupby('drug_admst'):
           print("Value: {}".format(value))
           print("Group DataFrame:")
           print(group)
```

Value: False

Group DataFrame:

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
e	F	150	90	130	85	False
f	M	117	74	121	74	False

Value: True

Group DataFrame:

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst
a	F	120	75	115	70	True
b	M	126	85	123	82	True
c	M	130	90	130	92	True
d	M	115	87	118	87	True

```
In [271]: df.groupby('drug_admst').agg({
           'sys_initial': ['min', 'max'],
           'sys_final': np.mean
           })
```

```
Out[271]:
```

		sys_initial		sys_final
		min	max	mean
drug_admst				
	False	117	150	125.5
	True	115	130	121.5

Joining

```
In [272]: hospitals = pd.DataFrame({
    "name" : ["City 1", "City 2", "City 3"],
    "address" : ["Address 1", "Address 2", "Address 3"],
    "city": ["City 1", "City 2", "City 3"]
    }, index=["H1", "H2", "H3"])

hospitals
```

```
Out[272]:
```

	name	address	city
H1	City 1	Address 1	City 1
H2	City 2	Address 2	City 2
H3	City 3	Address 3	City 3

```
In [273]: df['hospital_id'] = ['H1', 'H2', 'H2', 'H3', 'H3', 'H3']
df
```

```
Out[273]:
```

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst	hospital_id
a	F	120	75	115	70	True	H1
b	M	126	85	123	82	True	H2
c	M	130	90	130	92	True	H2
d	M	115	87	118	87	True	H3
e	F	150	90	130	85	False	H3
f	M	117	74	121	74	False	H3

```
In [274]: full_df = df.join(hospitals, on='hospital_id')
full_df
```

```
Out[274]:
```

	gender	sys_initial	dia_initial	sys_final	dia_final	drug_admst	hospital_id	name	address
a	F	120	75	115	70	True	H1	City 1	Address 1
b	M	126	85	123	82	True	H2	City 2	Address 2
c	M	130	90	130	92	True	H2	City 2	Address 2
d	M	115	87	118	87	True	H3	City 3	Address 3
e	F	150	90	130	85	False	H3	City 3	Address 3
f	M	117	74	121	74	False	H3	City 3	Address 3

Визуализация


matplotlib, seaborn

Pandas позволяет быстро создавать графики, используя API matplotlib.

Круговая диаграмма

```
In [275]: full_df['hospital_id'].value_counts().plot.pie(figsize=(5, 5))
```


```
Out[275]: <matplotlib.axes._subplots.AxesSubplot at 0x2592958a7c8>
```



Столбчатая диаграмма

```
In [276]: full_df['hospital_id'].value_counts().plot.bar()
```

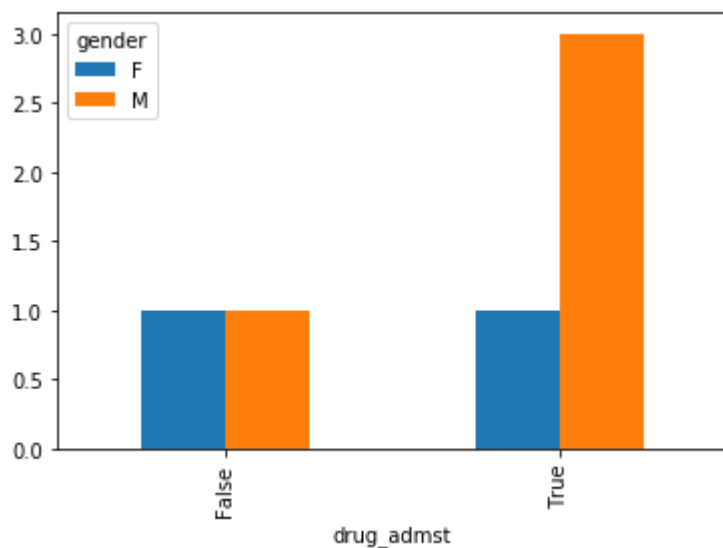
```
Out[276]: <matplotlib.axes._subplots.AxesSubplot at 0x259297c9e08>
```



Столбчатая диаграмма #2

```
In [279]: pd.crosstab(df.drug_admst, df.gender).plot.bar()
```


```
Out[279]: <matplotlib.axes._subplots.AxesSubplot at 0x25929754f88>
```



Линейный график

```
In [281]: columns = {  
    'sys': np.random.randint(low=100, high=200, size=10),  
    'dia': np.random.randint(low=50, high=150, size=10),  
}  
  
a_observations = pd.DataFrame(columns, index=pd.date_range('1/1/2020', periods  
=10))  
a_observations.plot()
```

```
Out[281]: <matplotlib.axes._subplots.AxesSubplot at 0x259298ea548>
```



Домашнее задание

Во вкладке **Files** в группе **Webinars** прикреплен файл `_olimpicmedals.csv` с данными о медалях на Олимпийских играх за 1896-2008 годы.

Ссылка:

https://epam.sharepoint.com/sites/EPAMNNPythonLab/Shared%20Documents/Webinars/olimpic_medals.csv
(https://epam.sharepoint.com/sites/EPAMNNPythonLab/Shared%20Documents/Webinars/olimpic_medals.csv)

Скачайте `.csv` файл себе на диск, загрузите данные в `DataFrame` (функция `_readcsv`) и ответьте на следующие вопросы, используя функционал `pandas`:

1. Сколько медалей выиграл Jesse Owens в 1936?
2. Какая страна выиграла большинство золотых медалей мужчинами в бадминтоне?
3. Какие три страны выиграли большинство медалей в последние годы (с 1984 по 2008)?
4. Покажите мужчин золотых медалистов по 100m. Выведите результаты по убыванию года выигрыша. Покажите город в котором проходила олимпиада, год, имя атлета и страну за которую он выступал.
5. Как много медалей было выиграно мужчинами и женщинами в истории олимпиады. Как много золотых, серебрянных и бронзовых медалей было выиграно каждым полом?
6. Используя `groupby()`, постройте график числа всех медалей выигранных на каждой олимпиаде.
7. Создайте список показывающий число всех медалей выигранных каждой страной в течение всей истории олимпийских игр. Для каждой страны, необходимо показать год первой и последней заработанной медали.
8. Атлеты выигравшие медали в Beijing на дистанции 100m или 200m
9. Постройте график числа золотых медалей выигранных США мужчинами и женщинами в атлетике.
10. Постройте график 5 атлетов которые выиграли большинство золотых медалей.
11. Покажите суммарное количество медалей выигранных странами в последних олимпийских играх.
12. Постройте таблицу в которой по годам всех олимпиад покажите топовых атлетов США(1 атлет на год) по общему количеству медалей. Включите дисциплину атлета.

Форма чтобы засабмитить задание: <https://epa.ms/pyhomework> (<https://epa.ms/pyhomework>)